Apache HBase : un SGBD NoSQL orienté colonne

Jonathan Lejeune

Sorbonne Université/LIP6-INRIA

DataCloud – Master 2 SAR 2020/2021

Motivations

Le stockage de données dans l'Eco-système Hadoop

HDFS :

- ✓ stockage de grand volume de données
- ✗ Accès séquentiel aux données :

  $\Rightarrow$ accès à une donnée ponctuelle stockée dans un fichier = un scan complet du cluster

  $\Rightarrow$ **coûteux en temps et en calcul**

Comment indexer et structurer des grandes masses de données pour un accès direct (random access) ?

Utilisation d'un SGBD

Apache Hbase

Bref historique

- Nov 2006 : Google publie un papier sur BigTable
- Oct 2007 : Premier Hbase "utilisable"
- Mai 2010 : HBase devient un projet Apache top-level
- Fev 2015 : Hbase 1.0.0
- Sep 2020 : HBase 2.2.6

Caractéristiques principales de HBase

Système d'indexation distribué

$\Rightarrow$ répartition de charge

Repose sur un système de fichiers distribué fiable (HDFS par défaut)

$\Rightarrow$ tolérance aux pannes, robustesse des données

Écritures/lectures directes sur un très grands ensemble de données

$\Rightarrow$ accès accélérés

Stockage NoSQL :

- orienté colonne :

  $\Rightarrow$ adapté aux traitements analytiques en ligne (OLAP)
- schéma clé $\rightarrow$ valeur

  $\Rightarrow$ accès rapide à une valeur par sa clé
- triée

  $\Rightarrow$ permet de récupérer les valeurs par intervalle de clés

Caractéristiques principales de HBase

Passage à l'échelle horizontal et linéaire

$\Rightarrow$ nombre de machines x 2 = stockage et puissance de calcul x2

Partitionnement automatique des données en régions

$\Rightarrow$ distribution et répartition des données transparentes pour l'utilisateur

Basculement automatique en cas de serveur de données défaillant

$\Rightarrow$ tolérance aux pannes transparentes pour l'utilisateur

Accès via Map-Reduce

$\Rightarrow$ traitement massivement parallèles

API Java

$\Rightarrow$ intégration naturelle dans l'ecosystème Hadoop

Organisation logique des données

Namespace1

Table1	ColumnFamily1				ColumnFamily2					
	Col1		Col2		Col3		Col4		Col5	
Rowkey1	vers2	**val1**	vers1	**val6**	vers1	**val7**	vers3	**val10**		
							vers2	**val11**		
	vers1	**val2**					vers1	**val12**		
Rowkey2	vers1	**val3**					vers1	**val13**	vers1	**val16**
Rowkey3			vers1	**val5**	vers1	**val9**	vers1	**val14**	vers1	**val15**

Namespaces

Namespace1

Table1	ColumnFamily1				ColumnFamily2					
	Col1		Col2		Col3		Col4		Col5	
Rowkey1	vers2	**val1**	vers1	**val6**	vers1	**val7**	vers3	**val10**		
							vers2	**val11**		
	vers1	**val2**					vers1	**val12**		
Rowkey2	vers1	**val3**					vers1	**val13**	vers1	**val16**
Rowkey3			vers1	**val5**	vers1	**val9**	vers1	**val14**	vers1	**val15**

Definition

- **Un groupement logique de table**

Caractéristiques

- Permet d'isoler des tables pour des raisons de quotas, de restrictions géographiques, de sécurité
- Deux namespace existent déjà par défaut
  - **hbase** : Contient toutes les tables des méta-données de HBase
  - **default** : namespace par défaut lorsque aucun namespace n'est spécifié à la création d'une table

Table

Namespace1

Table1	ColumnFamily1				ColumnFamily2					
	Col1		Col2		Col3		Col4		Col5	
Rowkey1	vers2	**val1**	vers1	**val6**	vers1	**val7**	vers3	**val10**		
							vers2	**val11**		
	vers1	**val2**					vers1	**val12**		
Rowkey2	vers1	**val3**					vers1	**val13**	vers1	**val16**
Rowkey3			vers1	**val5**	vers1	**val9**	vers1	**val14**	vers1	**val15**

Définition

- Élément servant à organiser les données dans HBase
- Le nom d'une table est une chaîne de caractères
- Désignée de manière non ambiguë en préfixant son nom par le nom de son namespace séparé par ' :'

```
nom_namespace:nom_table
```

Row

Namespace1

Table1	ColumnFamily1				ColumnFamily2					
	Col1		Col2		Col3		Col4		Col5	
Rowkey1	vers2	**val1**	vers1	**val6**	vers1	**val7**	vers3	**val10**		
							vers2	**val11**		
	vers1	**val2**					vers1	**val12**		
Rowkey2	vers1	**val3**					vers1	**val13**	vers1	**val16**
Rowkey3			vers1	**val5**	vers1	**val9**	vers1	**val14**	vers1	**val15**

Définition

- Permet d'organiser les données dans une table
- Une ligne est identifiée par une clé unique : **RowKey**
- La Rowkey n'a pas de type, c'est un tableau d'octets.

ColumnFamily

Namespace1

Table1	ColumnFamily1				ColumnFamily2					
	Col1		Col2		Col3		Col4		Col5	
Rowkey1	vers2	**val1**	vers1	**val6**	vers1	**val7**	vers3	**val10**		
							vers2	**val11**		
	vers1	**val2**					vers1	**val12**		
Rowkey2	vers1	**val3**					vers1	**val13**	vers1	**val16**
Rowkey3			vers1	**val5**	vers1	**val9**	vers1	**val14**	vers1	**val15**

Définition

- Regroupe les données au sein d'une ligne
- Toutes les lignes de la table ont les mêmes ColumnFamily, pouvant être peuplée ou pas
- Au moins une à la création de la table dans HBase

Column

Namespace1

Table1	ColumnFamily1				ColumnFamily2					
	Col1		Col2		Col3		Col4		Col5	
Rowkey1	vers2	**val1**	vers1	**val6**	vers1	**val7**	vers3	**val10**		
	vers1	**val2**					vers2	**val11**		
							vers1	**val12**		
Rowkey2	vers1	**val3**					vers1	**val13**	vers1	**val16**
Rowkey3			vers1	**val5**	vers1	**val9**	vers1	**val14**	vers1	**val15**

Définition

- Permet de subdiviser les columnfamily
- Désignée par une chaîne de caractères appelée **column qualifier**
- Spécifiée au moment de l'insertion de la donnée
- Non typée, le nom est un tableau d'octets

Cell

Namespace1

Table1	ColumnFamily				ColumnFamily2					
	Col1		Col2		Col3		Col4		Col5	
Rowkey1	vers2	**val1**	vers1	**val6**	vers1	**val7**	vers3	**val10**		
	vers2	**val11**								
	vers1	**val2**					vers1	**val12**		
Rowkey2	vers1	**val3**					vers1	**val13**	vers1	**val16**
Rowkey3			vers1	**val5**	vers1	**val9**	vers1	**val14**	vers1	**val15**

Définition

- Identifiée par la combinaison d'un RowKey, de la Column Family et de la Column
- Les données stockées dans une cellule sont les valeurs de la cellule
- On peut stocker différentes versions de la cellule (ou timestamp)

Version

Namespace1

Table1	ColumnFamily1				ColumnFamily2					
	Col1		Col2		Col3		Col4		Col5	
Rowkey1	vers2	**val1**	vers1	**val6**	vers1	**val7**	vers3	**val10**		
							vers2	**val11**		
	vers1	**val2**					vers1	**val12**		
Rowkey2	vers1	**val3**					vers1	**val13**	vers1	**val16**
Rowkey3			vers1	**val5**	vers1	**val9**	vers1	**val14**	vers1	**val15**

Définition

- Les valeurs au sein d'une cellule sont versionnées
- Les versions sont identifiées par défaut par un timestamp (de type long)
- Le nombre de versions stockables par cellule est paramétrable

Valeur

Namespace1

Table1	ColumnFamily1				ColumnFamily2					
	Col1		Col2		Col3		Col4		Col5	
Rowkey1	vers2	**val1**	vers1	**val6**	vers1	**val7**	vers3	**val10**		
	vers1	**val2**					vers2	**val11**		
							vers1	**val12**		
Rowkey2	vers1	**val3**					vers1	**val13**	vers1	**val16**
Rowkey3			vers1	**val5**	vers1	**val9**	vers1	**val14**	vers1	**val15**

Définition

- Une valeur est une donnée atomique de la base
- Non typée et stockée au format binaire
- Les valeurs null ne sont pas matérialisées (aucun stockage nécessaire)
- Désignée par une clé multi-dimensionnelle :
  (rowkey, column family, column, version)

Désignation complète d'une valeur dans HBase

namespace :table(rowkey, column family, column, version) –> val

Architecture globale

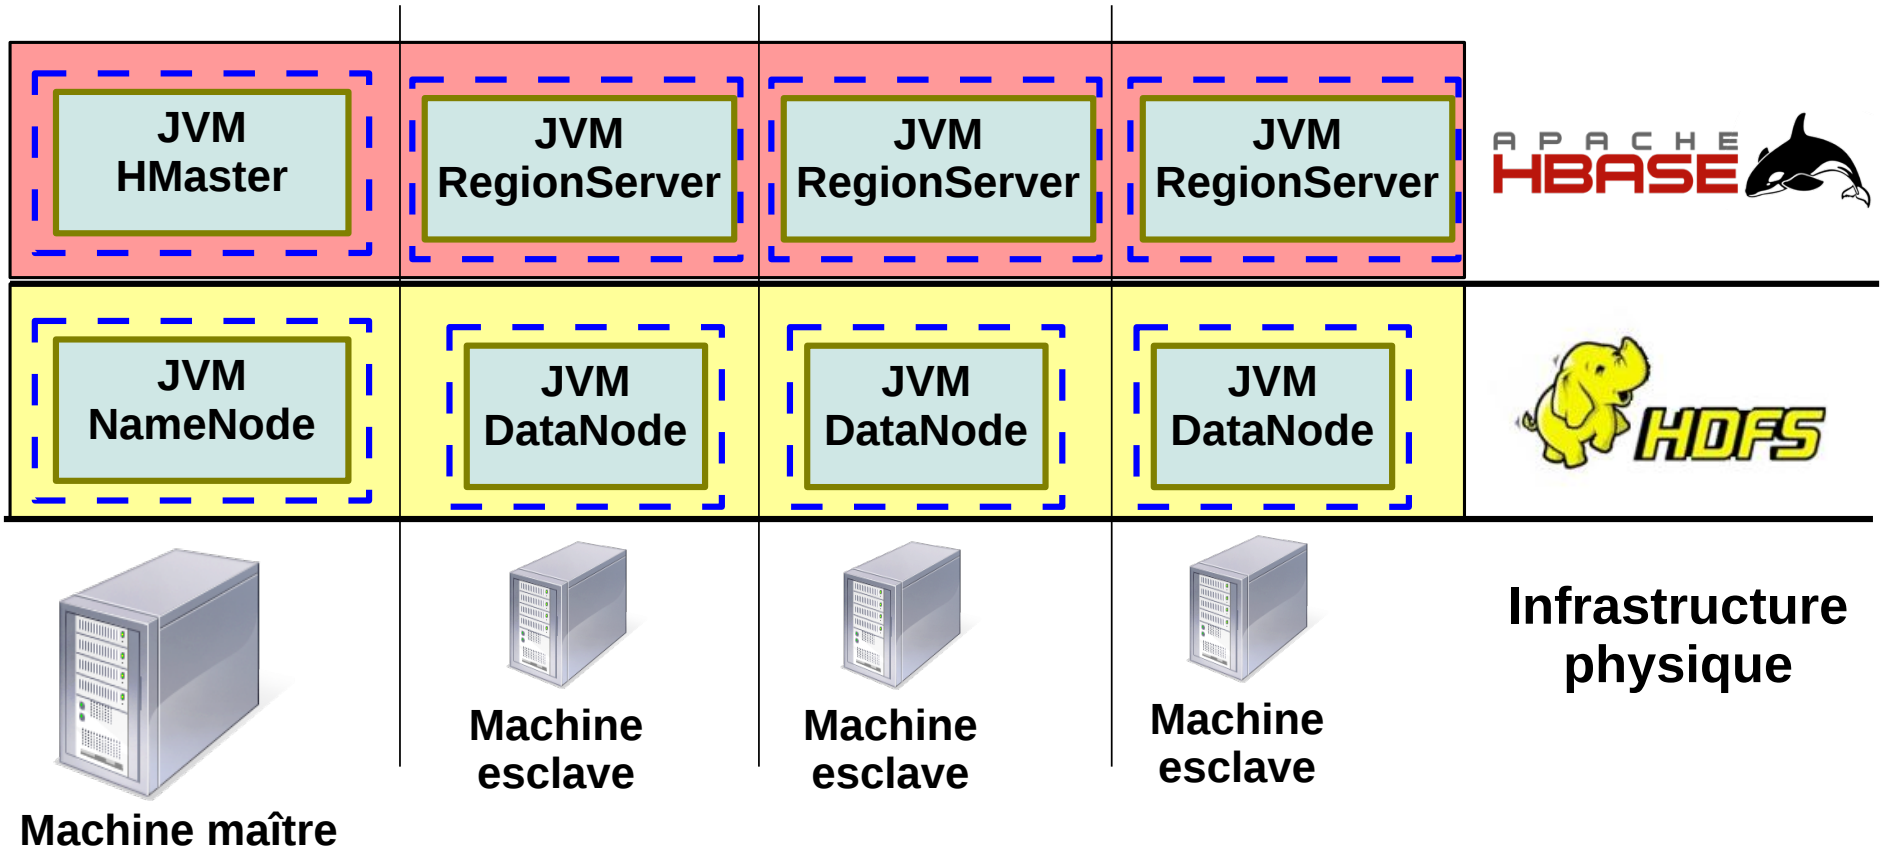

Une architecture maître esclave

- Nœud maître = Hmaster, Nœud esclave = RegionServer
- Correspondance directe avec le cluster HDFS

Découpage des données sur le cluster

RegionServer

Region 1

RegionServer

Region 2

RegionServer

Region 3

Table1	ColumnFamily1			ColumnFamily2	
	Col1	Col2	Col3	Col4	Col5
Rowkey1					
Rowkey2					
Rowkey3					
Rowkey4					
Rowkey5					
Rowkey6					
Rowkey7					
Rowkey8					
Rowkey9					

Région

- Sous ensemble contiguë de lignes de la table
- Stockée sur un nœud physique esclave et triée selon la rowkey
- Identifiée par un rowkey minimum et un rowkey maximum

RegionServer

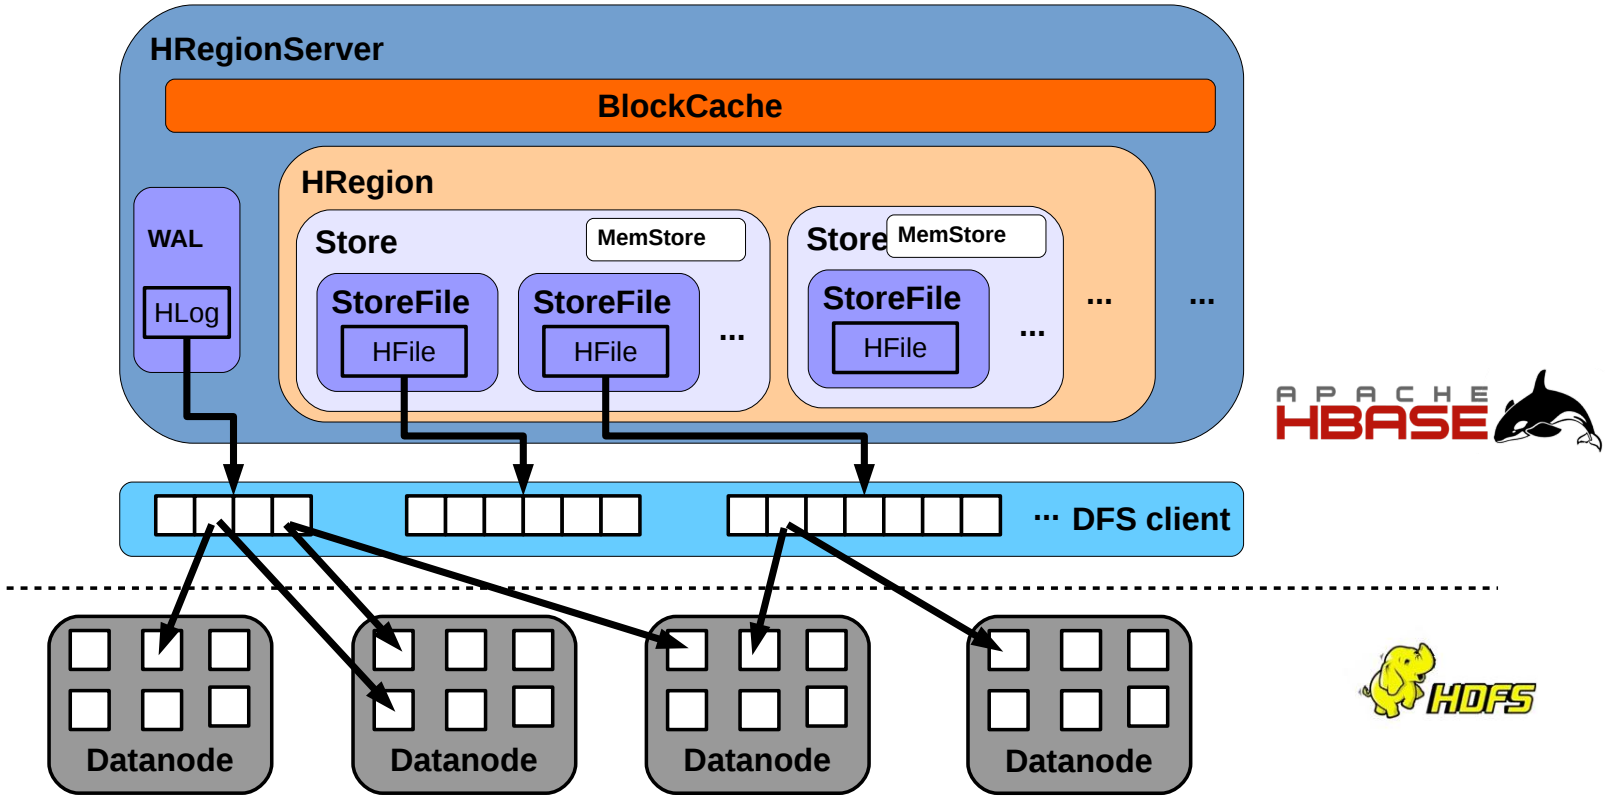

Caractéristiques principales

- Point d'entrée pour accéder à une donnée
- Propose les services :
  - Données (get, put,delete,next, etc.)
  - Region (splitRegion, compactRegion, etc.)

RegionServer : BlockCache

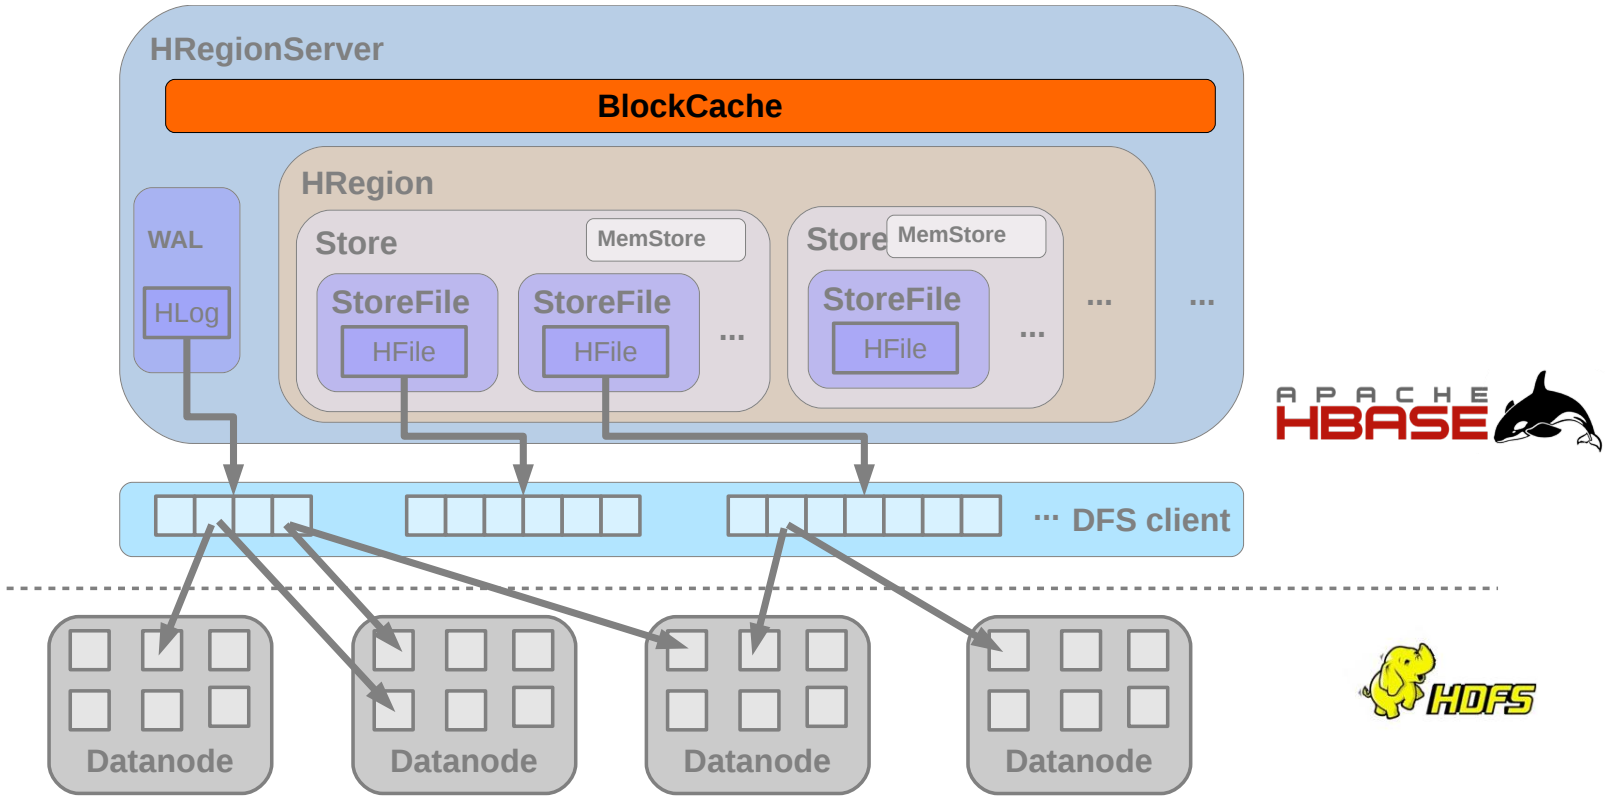

Caractéristique du BlockCache

Cache LRU activé par défaut pour toutes les tables

$\Rightarrow$ Toute opération de lecture est chargée dans le cache LRU.

RegionServer : Write Ahead Log (WAL)

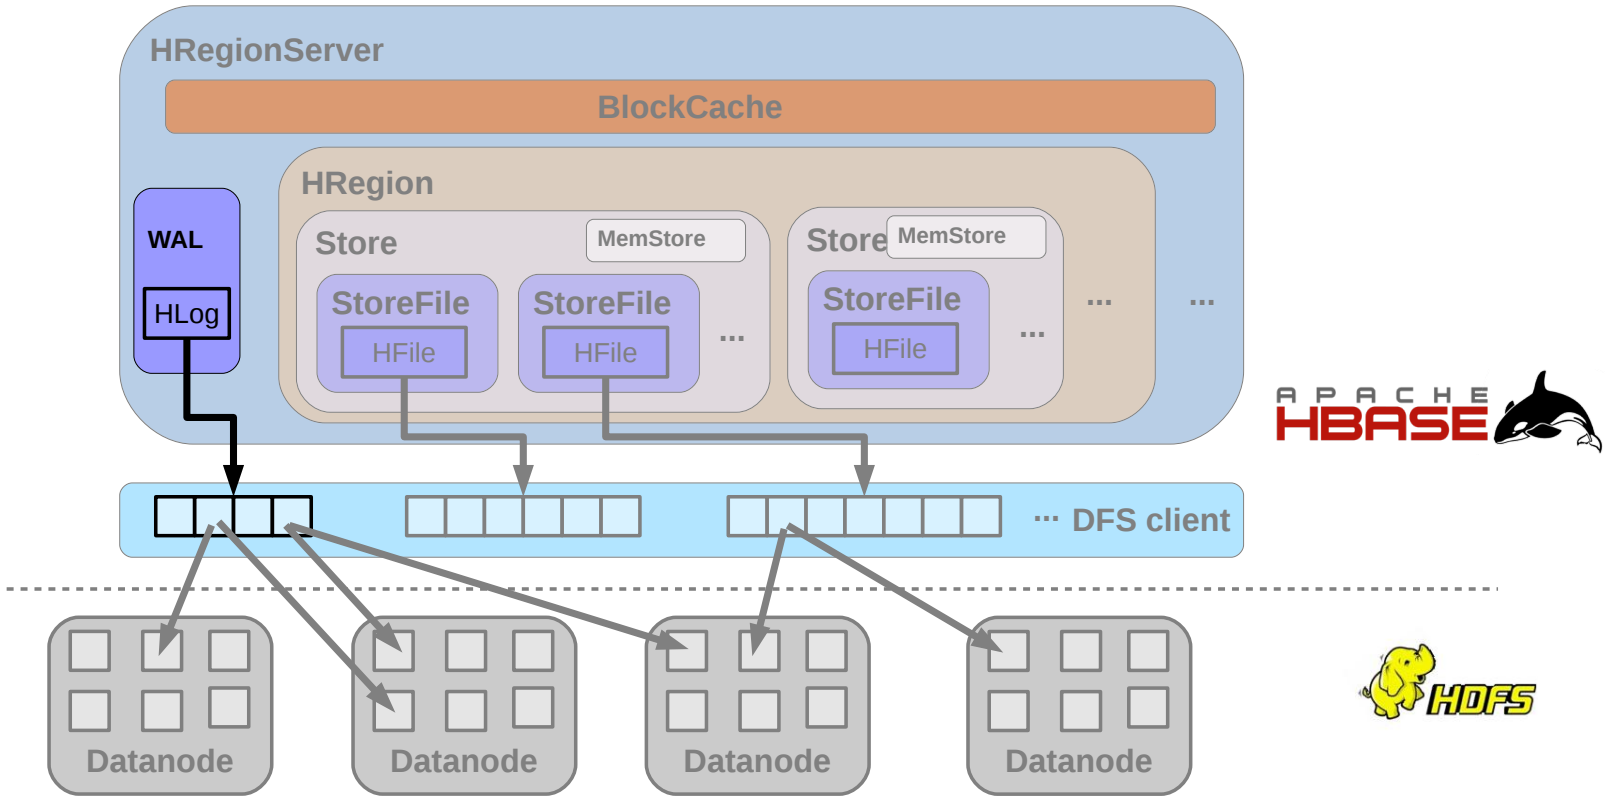

Caractéristiques des WAL

- Loguent les ajouts/mises à jour fait sur le RegionServer
- Garantissent la durabilité de la donnée en cas de défaillance
- Stockent les informations dans un fichier HDFS HLog

RegionServer : HRegion

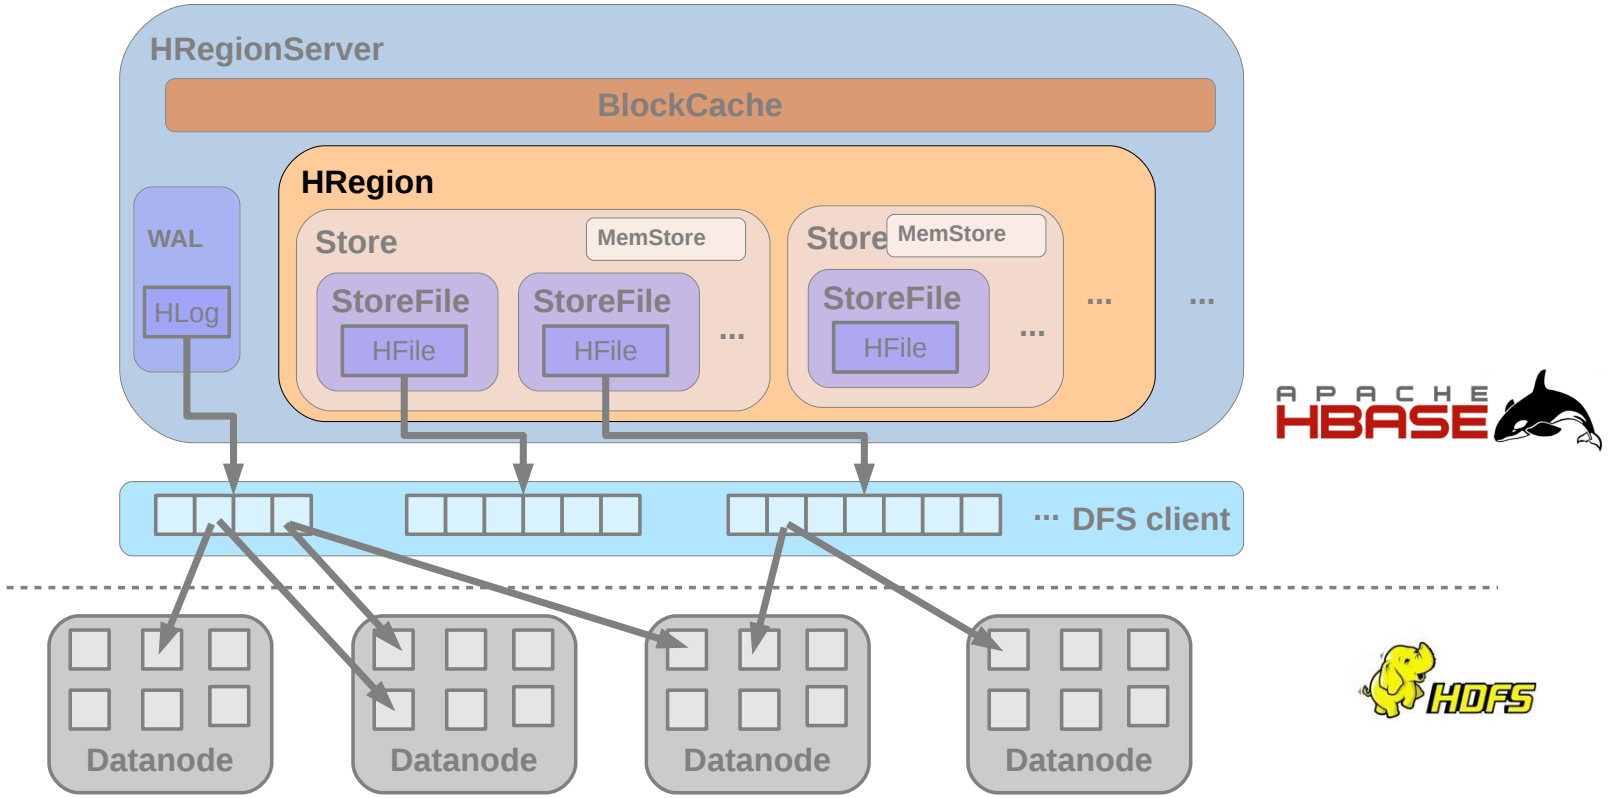

Caractéristiques des HRegion

- Représente une région
- Gére un sous ensemble de lignes contiguës d'une table Hbase

RegionServer : Store

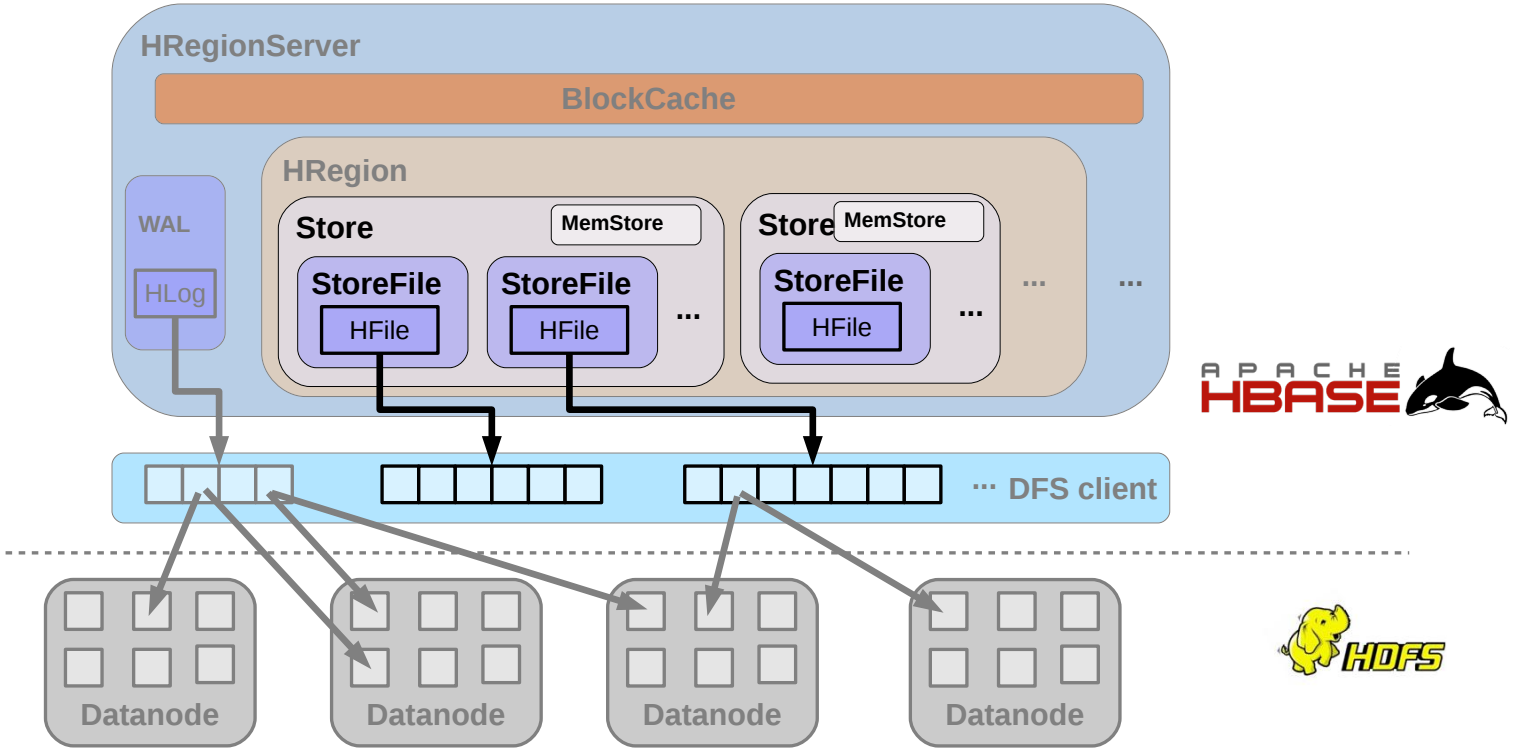

Caractéristiques des Stores

- Représente une columnFamily de la région
- Appartient à une seule région
- Le cache memStore stocke toutes les écritures relatives à la partition
- Stocke les données physiquement dans plusieurs fichiers HDFS.

Découpage des tables

Résumé

- Une table est segmentée en plusieurs partitions (= région)
- Une région d'une table est gérée par un RegionServer
- Un RegionServer gère plusieurs Regions
- Une Region contient plusieurs Stores
- Chaque Store gère une ColomnFamily d'une table
- Un Store gère un MemStore et plusieurs StoreFile
- Un StoreFile gère un fichier de stockage de la partition

HMaster

Caractéristiques

- Coordonne et surveille les RegionServer : les remplace si besoin
- Interface pour tout changement des meta-données du système (table hbase :meta) :
  ex : création/suppression/modif d'une table ou d'une col family
- Assure l'équilibre de charge entre RegionServer :
  (dé)assigne/déplace les régions
- Peut être répliqué

En cas de panne :

- un des réplicas prend sa place
- pendant la gestion de la panne, HBase peut continuer à fonctionner car les clients s'adressent directement aux RegionServer

Zookeeper

Caractéristiques

- Logiciel Apache de de coordination de systèmes distribués
- Entrepôt de méta-données partagées
- Surveillance et notification d'événements

Rôle pour HBase

- Notifie le HMaster en cas de panne d'un RegionServer
- Stocke la localisation de la table hbase :meta dans le cluster

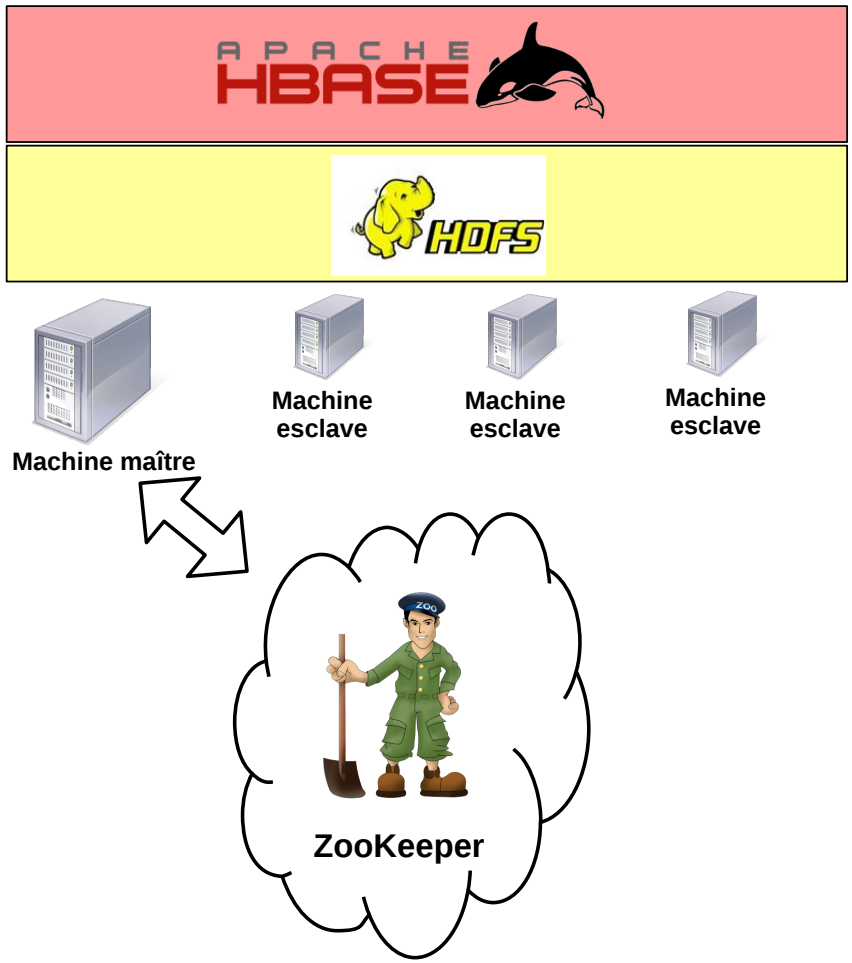

La table hbase :meta

Caractéristiques

- Maintien la liste de toutes les régions du système
- La localisation des régions de cette table est stockée dans ZooKeeper

hbase

meta	info		
	regioninfo	server	serverstartcode
(nom_table, clé de départ, id_region)	<info diverse>	<adresseIP:port du serveur>	<date a laquelle la region a été crée sur le serveur>

Accès à une donnée depuis un client

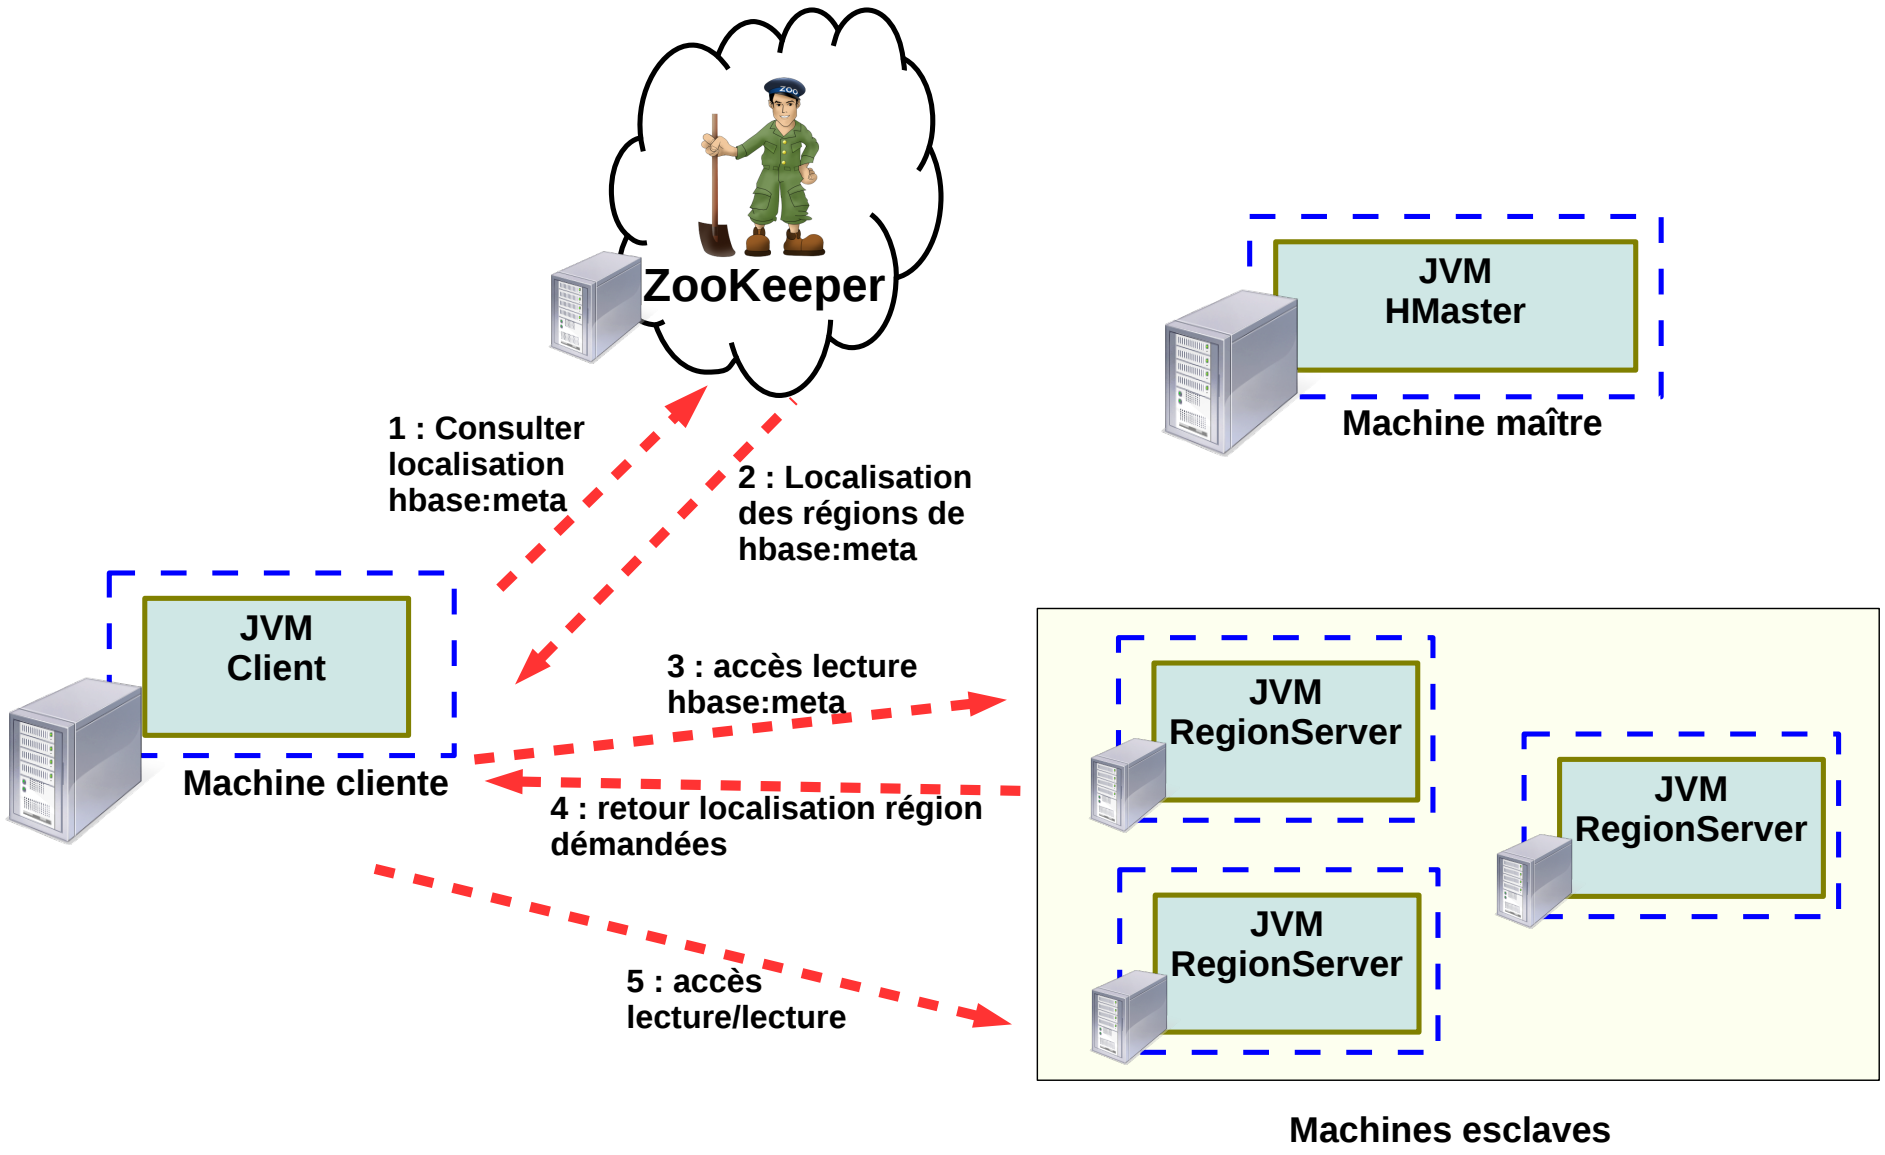

Cas d'une écriture

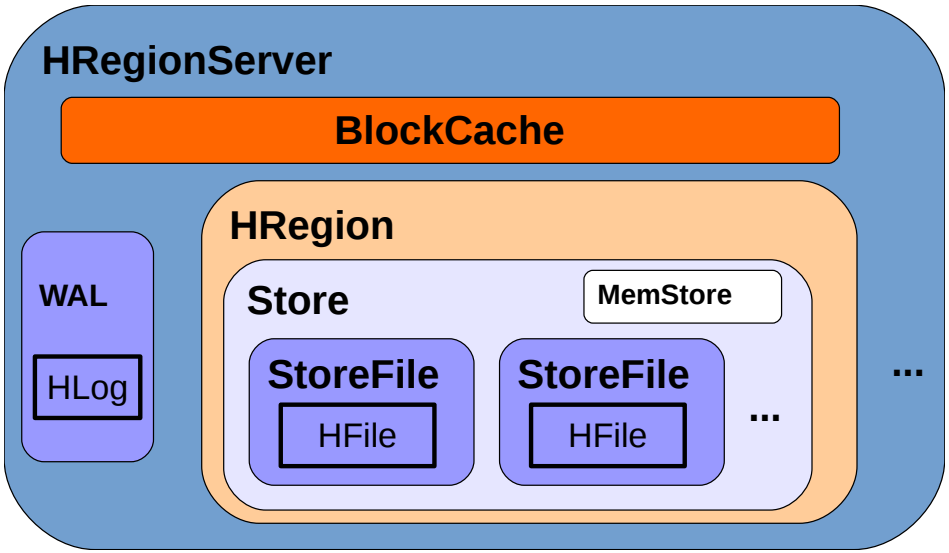

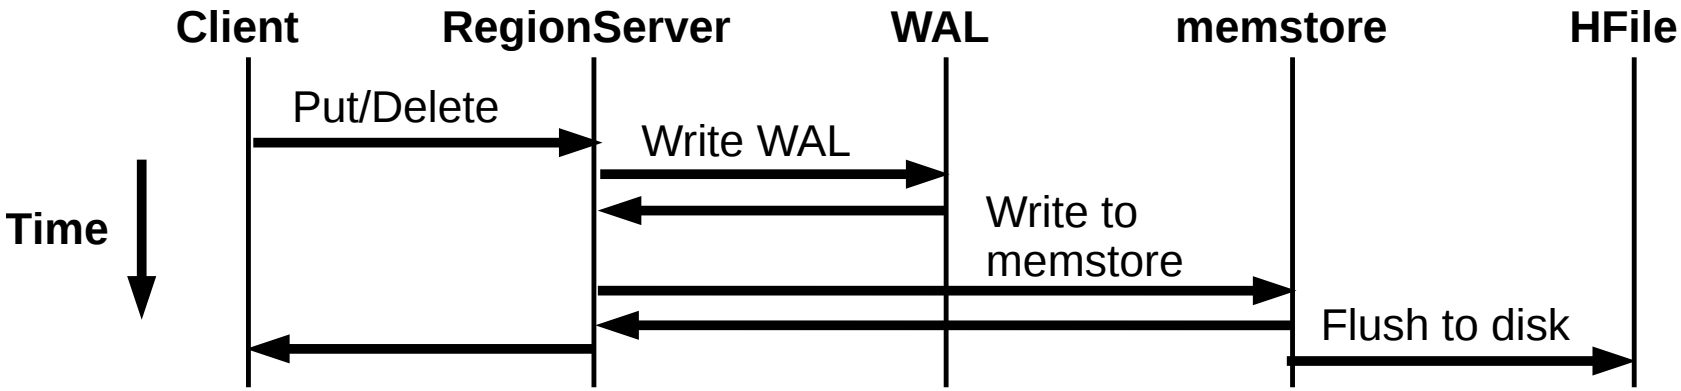

Manipuler HBase

les API

- un shell dédié en lançant la commande `hbase shell`
- API JAVA native
- API externes :
  - REST
  - Thrift

API Java : Connexion/déconnexion à Hbase

Connexion à Hbase

```
Configuration conf = HBaseConfiguration.create();
conf.set("hbase.zookeeper.quorum", "server1.com,server2.fr");
Connection c = ConnectionFactory.createConnection(conf);
...//code client Hbase
c.close();//fermeture connexion
```

Connexion/déconnexion à une table

```
Connection c = ..;
TableName tableName = TableName.valueOf("ma_table");
Table table = c.getTable(tableName);
...
table.close();//fermeture desc table
```

Caractéristiques

- `"hbase.zookeeper.quorum"` = machines serveurs de ZK (par def : `localhost`)
- **Recommandation** : une unique connexion par JVM cliente
  - une connexion à ZooKeeper est coûteuse
  - les données de ZK sont en cache sur la machine cliente

API Java : le typage des données

RAPPEL

Dans Hbase les données ne sont pas typées et sont stockées au format binaire :

⇒ Nécessité de convertir toutes les données du programme :

- du type java d'origine vers `byte[]` avant une écriture
- de `byte[]` vers le type Java d'origine après une lecture

La classe utilitaire Bytes

Vers le binaire

```
static byte[] toBytes(String s);
static byte[] toBytes(boolean b);
static byte[] toBytes(long val);
static byte[] toBytes(float f);
static byte[] toBytes(int val);
...
```

Depuis le binaire

```
static String toString(byte[] bytes);
static boolean toBoolean(byte[] bytes);
static long toLong(byte[] bytes);
static float toFloat(byte[] bytes);
static int toInt(byte[] bytes);
...
```

API Java : création/suppression d'une table

Construire le descripteur d'une table

```
TableName tn = TableName.valueOf(namespace,nametable);
TableDescriptorBuilder tdb =
                TableDescriptorBuilder.newBuilder(tn);
for(String cf : column_families_names){
 tdb.setColumnFamily(
  ColumnFamilyDescriptorBuilder.newBuilder(cf.getBytes).build()
 );
}
TableDescriptor td = tdb.build();
```

Création d'une table

```
Connection c = .......;
c.getAdmin().createTable(td);
```

Suppression d'une table

```
Connection c = .......;
c.getAdmin().disableTable(td.getTableName())
c.getAdmin().deleteTable(td.getTableName())
```

API Java : Opération de lecture/écriture sur les tables

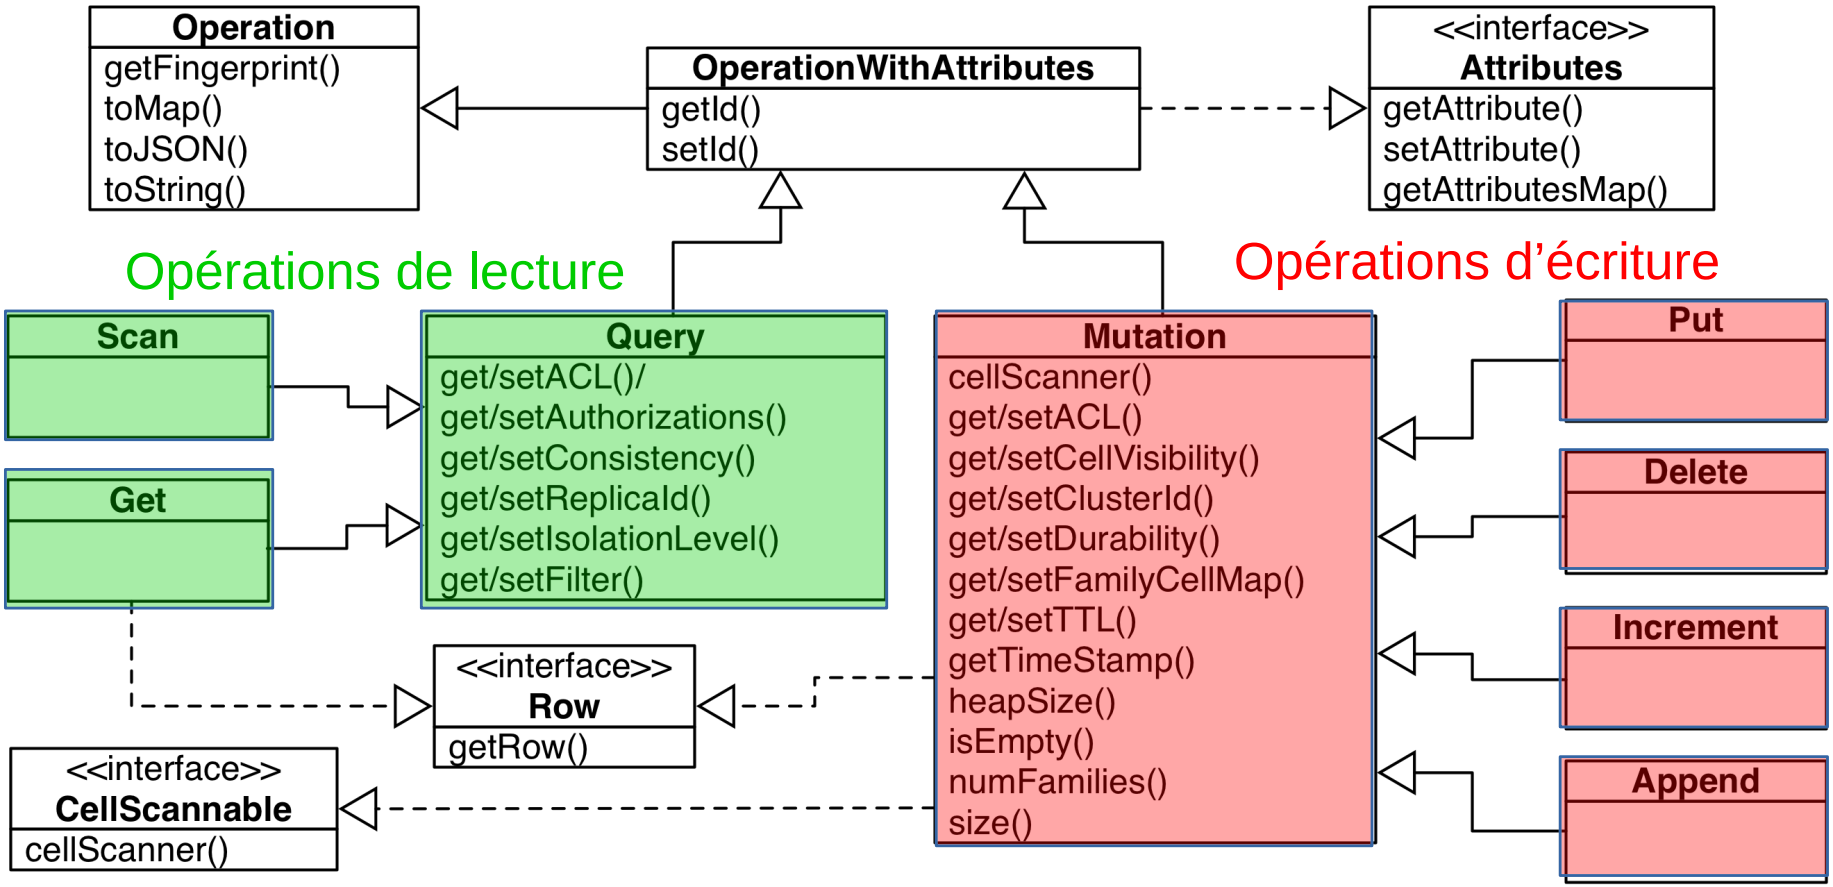

API Java : les mutations Put

Caractéristiques

- Objet caractérisant une ou plusieurs écritures/ modifications d'une ligne
- constructeurs : `Put(byte[] rowkey)` ou `Put(byte[] rowkey, long def_ts)`
- Ajouter une colonne à créer/à modifier :

```
Put addColumn(byte[] family, byte[] col, byte[] val);
Put addColumn(byte[] family, byte[] col, long ts, byte[] val);
```

Exemple d'utilisation

```
Table table = ....;//connexion à une table
Put put = new Put(Bytes.toBytes("row1"));
//ajout d'une valeur v1 dans la cellule <row1,cf1:c1>
put.addColumn(Bytes.toBytes("cf1"), Bytes.toBytes("c1")
                                  , Bytes.toBytes("v1"));
//ajout d'une valeur v2 dans la cellule <row1,cf1:c2>
put.addColumn(Bytes.toBytes("cf1"), Bytes.toBytes("c2")
                                  , Bytes.toBytes("v2"));

table.put(put);//envoi de la requête sur la table
```

API Java : les autres Mutations

les Deletes

- Objet caractérisant la suppression partielle ou totale des colonnes d'une ligne
- constructeur : `Delete(byte[] rowkey)`

les Appends

- Objet caractérisant une opération atomique de read-modify-write sur la cellule d'une ligne
- constructeur : `Append(byte[] row)`
- méthode : `Append add(byte[] family, byte[] col, byte[] value)`
  $\Rightarrow$ création d'une nouvelle version de la cellule en concaténant l'ancienne valeur avec la nouvelle valeur

API Java : les Query Get

Caractéristiques

- Objet caractérisant la lecture partielle ou totale d'une ligne
- constructeur : `Get(byte[] rowkey)`
- Ajouter des critères de sélections :

```
Get addFamily(byte[] family);
Get addColumn(byte[] family, byte[] qualifier);
Get setTimeRange(long minStamp, long maxStamp);
Get setMaxVersions(int maxVersions);
```

- le résultat d'une lecture est un objet de type `Result` qui contient toutes les cellules qui correspondent aux critères de la requête

Exemple d'utilisation

```
Table table = ....;//connexion à une table
Get get = new Get(Bytes.toBytes("row1"));
get.addColumn(Bytes.toBytes("cf1"), Bytes.toBytes("c1"));

Result res = table.get(get);//envoi de la requête sur la table
byte[] val = res.getValue(Bytes.toBytes("cf1"),Bytes.toBytes("c1"));
System.out.println(Bytes.toString(val));
```

API Java : les Query Scan

Caractéristiques

- Objet caractérisant la lecture séquentielle de plusieurs lignes
- constructeurs :
  - `Scan()` : toute la table
  - `Scan(byte[] startRowKey)` : à partir d'une ligne donnée
  - `Scan(byte[] startRowkey, byte[] stopRowKey)` : sur une portion
- mêmes méthodes que `Get`

Exemple d'utilisation

```
Table table = ....;//connexion à une table
Scan scan = new Scan(Bytes.toBytes("rowX"), Bytes.toBytes("rowY"));
scan.addColumn(Bytes.toBytes("cfz"), Bytes.toBytes("col"));
ResultScanner results = table.getScanner(scan);
for(Result res: results){
   System.out.println(res);
}
```

Hbase et Job MapReduce

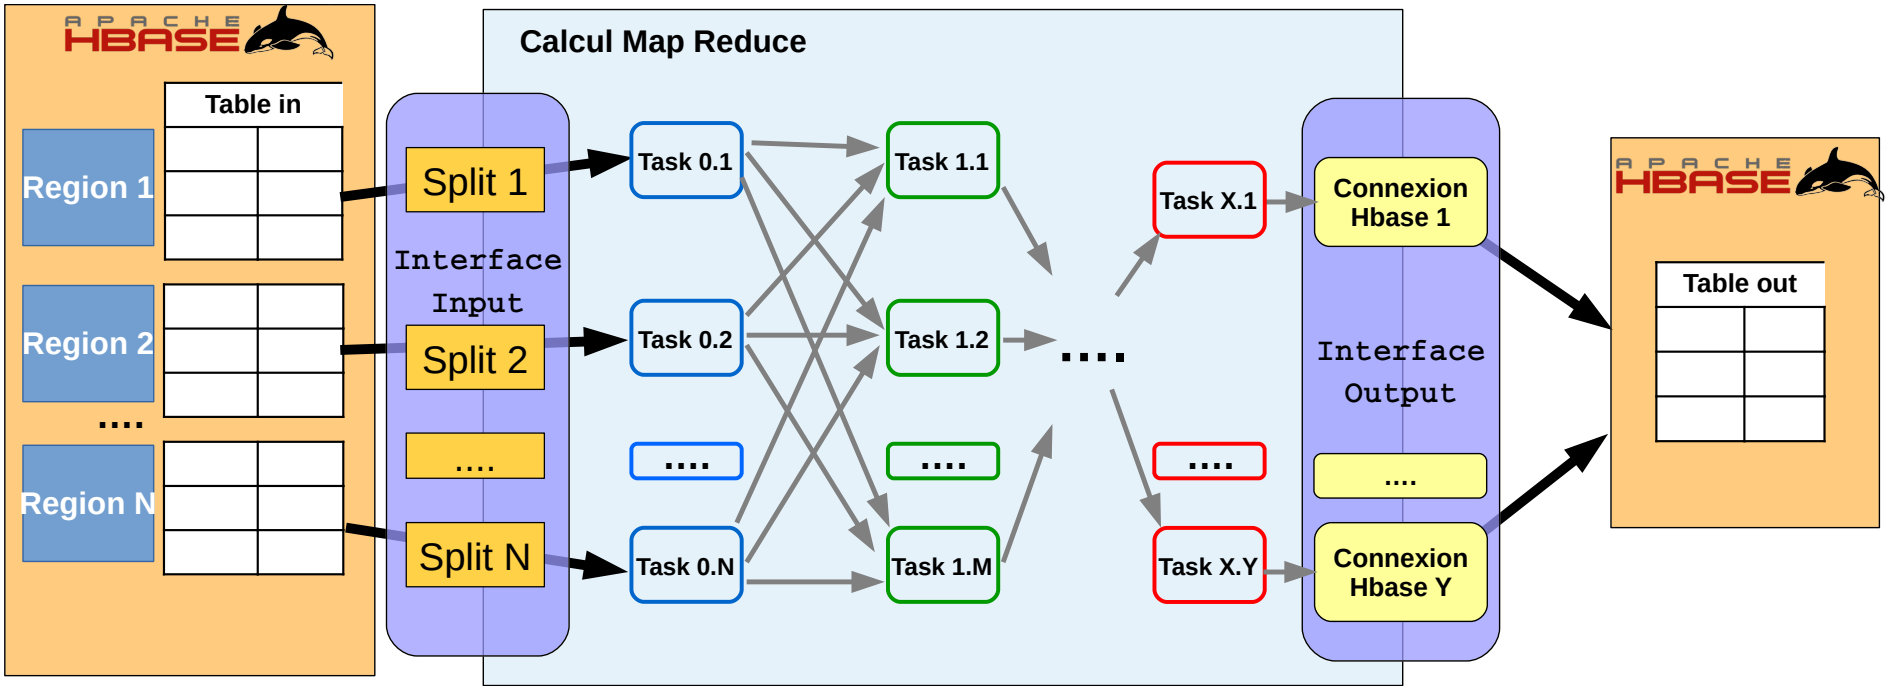

Principes

- Une tâche de début est affecté à une région
- Une tâche de fin écrit dans la base

⇒ **Toute tâche de début ou de fin est un client Hbase**

Propriétés garanties par HBase

Atomicité

- Toute mutation est atomique pour une ligne entière et peut être :
  - soit "success" $\Rightarrow$ réussite complète
  - soit "failed" $\Rightarrow$ échec complet
- L'ordre de mutations concurrentes pour une ligne se fait sans entrelacement.

  ex : si "a=1,b=1" $\|$ "a=2,b=2" alors soit "a=1,b=1" ou soit "a=2,b=2"
- L'atomicité n'est pas garantie sur plusieurs lignes

Propriétés garanties par HBase

Cohérence

- Tout get sur une ligne complète retournera une version de la ligne qui a existé dans l'histoire de la table :

  si 1 *get* || plusieurs mutations, alors le *get* retournera une ligne complète qui a existé a un point donné dans le temps entre les mutations
- Un scan n'est pas une vue cohérente de la table
- Toute ligne retournée par un scan est cohérente et est au moins aussi récente que le début du scan

Durabilité

- Toute donnée visible est durable $\Rightarrow$ un read concerne forcément une donnée validée
- Toute opération acquittée réussie est durable
- Toute opération acquittée échec ne sera pas durable

Références

[1] http ://hbase.apache.org/book.html

[2] https ://www.tutorialspoint.com/hbase

[3] HBase : The Definitive Guide, 2nd Edition, Lars George, O'Reilly Media, Inc., ISBN : 9781491905845